

Rapport - Det egna projektet i Python för AI

Projekt: Klassificering av Iris-blommor med logistisk regression

1. Problem och dataset

I detta projekt har jag valt att arbeta med Iris-datasetet från Scikit-learn. Målet är att bygga en enkel maskininlärningsmodell som kan förutsäga vilken art en Iris-blomma tillhör utifrån fyra numeriska mätvärden: sepal length, sepal width, petal length och petal width.

Detta är ett klassificeringsproblem eftersom modellen ska dela in varje observation i en av tre klasser: setosa, versicolor eller virginica. Jag valde detta dataset eftersom det är tydligt, lagom stort och passar bra för en första fungerande maskininlärningslösning.

2. Förberedelse av data

Datasetet laddades in i en Jupyter Notebook och omvandlades till en DataFrame för att göra det lättare att undersöka. Jag kontrollerade antal rader, kolumner och om det fanns saknade värden. Datasetet innehöll inga saknade värden, vilket gjorde att ingen imputering behövdes.

Alla features i datasetet är numeriska. Eftersom jag valde logistisk regression standardiserades de numeriska variablerna med StandardScaler. Standardisering gör att variabler med olika skala behandlas mer jämnt av modellen. Jag använde alla fyra features eftersom de tillsammans beskriver blomman och är relevanta för att kunna förutsäga arten.

Jag skapade också en visualisering där petal length jämfördes med petal width. Visualiseringen visade att arterna skiljer sig ganska tydligt åt, särskilt med hjälp av dessa två variabler.

3. Val av modell och träning

Jag valde logistisk regression som modell. Modellen passar bra eftersom uppgiften är klassificering och eftersom den är enkel, tydlig och tillräcklig för en grundläggande lösning. Datasetet delades upp i träningsdata och testdata, där 80 procent användes för träning och 20 procent för testning.

För att göra arbetsflödet tydligt skapades en pipeline med två steg: först StandardScaler för standardisering och därefter LogisticRegression för klassificering. Modellen tränades på träningsdatan och testades sedan på den separata testdatan.

4. Utvärdering och resultat

Modellen utvärderades med accuracy, precision, recall och F1-score. På testdatan fick modellen en hög accuracy. Det betyder att modellen klassificerade de flesta blommorna korrekt. Jag använde även en confusion matrix för att se vilka klasser modellen eventuellt blandade ihop.

Resultatet visar att modellen fungerar bra för detta dataset. En viktig anledning är att Iris-datasetet är relativt enkelt och att vissa features, särskilt petal length och petal width, tydligt skiljer arterna åt.

5. Reflektion, begränsningar och förbättringsförslag

Även om modellen presterar bra finns det begränsningar. Datasetet är litet och rent, vilket innebär att det inte helt motsvarar verkliga situationer där data kan innehålla fel, saknade värden eller större variation. Om modellen skulle användas i verkligheten behövs mer data och mer testning för att säkerställa att modellen fungerar på nya exempel.

Möjliga förbättringar är att testa fler modeller, till exempel beslutsträd eller Random Forest, använda korsvalidering för en mer stabil utvärdering och göra hyperparametertuning. Man kan också undersöka om vissa features är viktigare än andra. Det är även viktigt att reflektera över bias: om datasetet inte representerar alla verkliga variationer kan modellen fungera sämre på nya eller ovanliga exempel.

6. Sammanfattning

Projektet uppfyller målet att skapa en enkel och fungerande maskininlärningslösning. Ett tydligt problem och dataset valdes, datat förbereddes, en modell tränades och resultatet utvärderades med relevanta metoder. Lösningen är enkel men komplett och passar därför bra för kraven på Godkänt.